

Bruno Severino Mascarenhas

Relatório das Práticas Laboratoriais

Visão Computacional e Reconhecimento  
de Padrões

Salvador

2021

## Sumário

1 Introdução.....	3
2 Prática 1 – Pré-processamento de imagem.....	3
2.1 Objetivo.....	3
2.2 Descrição da prática.....	3
2.2.1 Roteiro I.....	3
2.2.2 Roteiro II.....	4
2.3 Análise crítica dos resultados.....	4
2.3.1 Equalização de Histograma.....	4
2.3.2 Correção de Gamma.....	6
2.3.3 Filtro Gaussiano.....	8
2.3.4 Filtro de Laplace.....	10
2.3.5 Invariância de cor.....	11
3 Referências.....	15

# 1 Introdução

Pela natureza da estrutura de dados em que representamos a imagem digitalmente, uma matriz apenas com uma dimensão caso esteja em escala de cinza ou com três dimensões, um para cada cor primária do modelo aditivo (vermelho, verde e azul) podemos realizar algumas inferências através da análise do seu histograma de cores (distribuição de frequência). As características extraídas das imagens foram analisadas em consideração ao seu histograma de cores, resultado final na imagem e a sua invariância de cor.

Durante o desenvolvimento dos experimentos a imagem foi redimensionada em 150 por 150 pixels (150x150) e transformada em inteiro sem sinal de 8 bits (UINT8), sendo representado por 0 o valor com menor intensidade e o 255 o valor com maior intensidade, ou respectivamente preto e branco numa escala de cinza.

## 2 Prática 1 – Pré-processamento de imagem

### 2.1 Objetivo

Nessa prática, algumas operações de pré-processamento de imagem são apresentadas. O objetivo é estudar os impactos dessas operações no desempenho do classificador, o qual será objeto de práticas posteriores. Com isso, espera-se motivar reflexões sobre a conveniência de se utilizar operações de pré-processamento de imagens em um sistema de Visão Computacional.

### 2.2 Descrição da prática

#### 2.2.1 Roteiro I

1. Aplique a equalização de histograma nas imagens do dataset original (treino e teste). Em seguida, salve os resultados dos novos datasets;
2. Aplique correção gamma nas imagens do dataset original (treino e teste), utilizando três diferentes valores de gamma (ajuste os parâmetros a seu critério). Em seguida, salve os resultados dos novos datasets;

3. Suavize as imagens do dataset original, aplicando um filtro gaussiano (ajuste os parâmetros a seu critério). Em seguida, salve os resultados do novo dataset;
4. Realize o aguçamento das imagens no dataset original, aplicando o filtro laplace (ajuste os parâmetros a seu critério). Em seguida, salve os resultados do novo dataset.

## 2.2.2 Roteiro II

1. Implemente as transformações de cor do cabeçalho da Figura 1, utilizando 3 imagens do dataset original 1. Além disso, realize a extração das seguintes features:

- Histograma RGB
- $O_1, O_2$
- Transformada de Cor

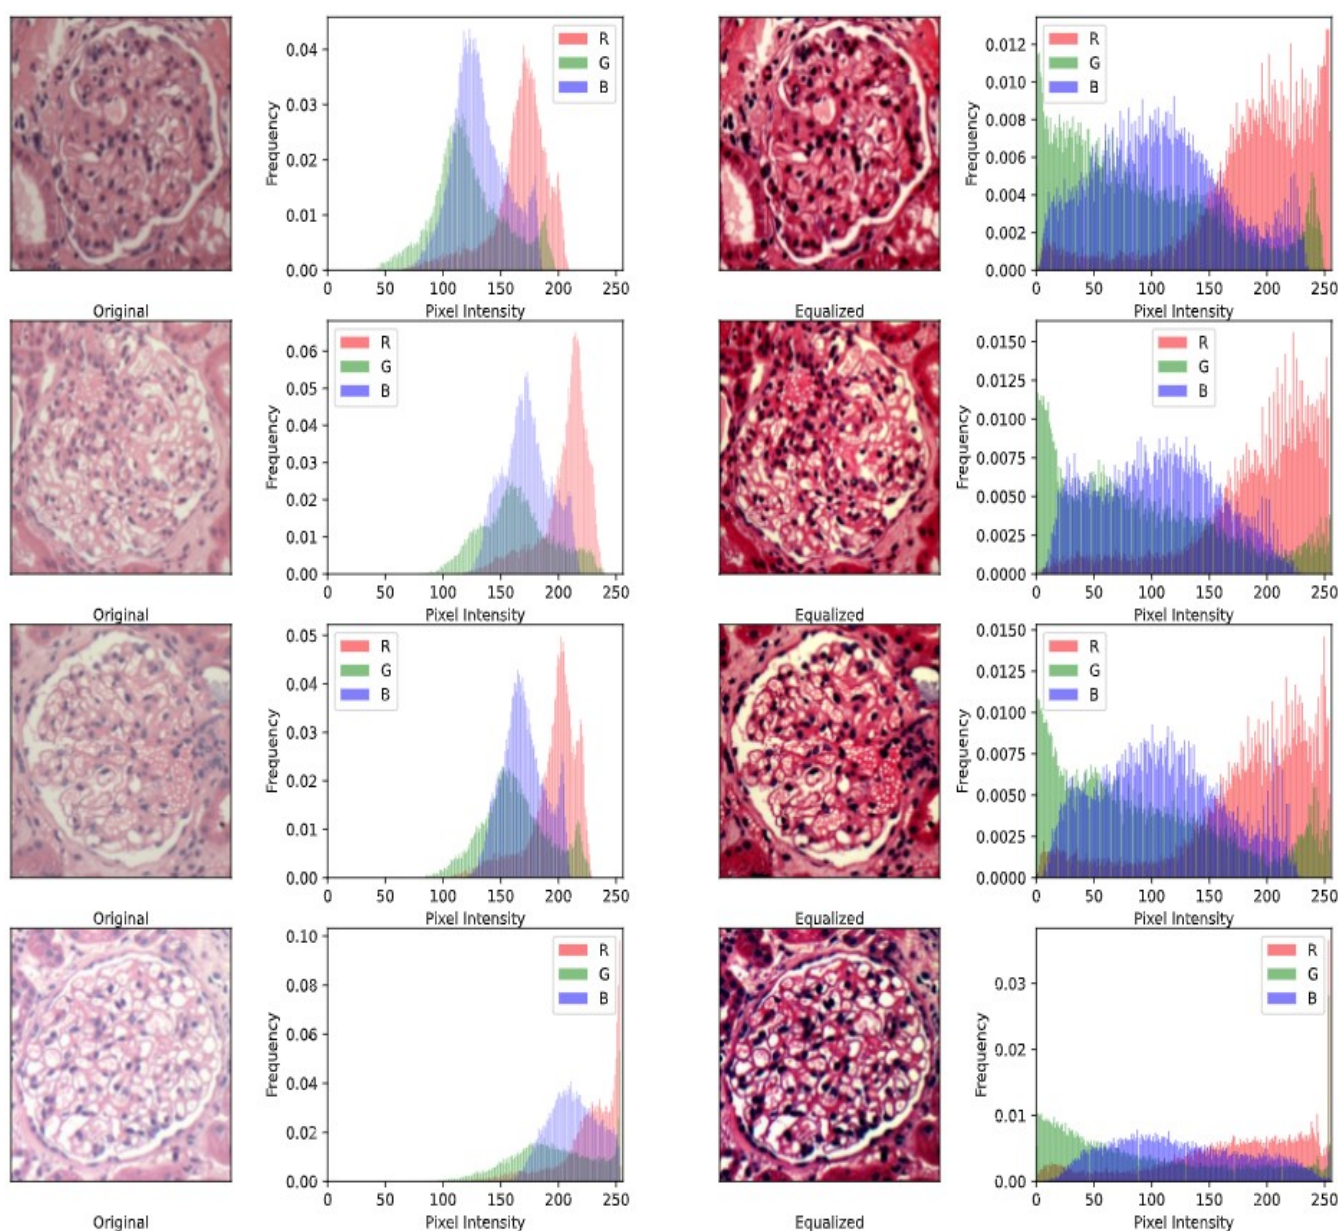
	Light intensity change $\begin{pmatrix} a & 0 & 0 \\ 0 & a & 0 \\ 0 & 0 & a \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix}$	Light intensity shift $\begin{pmatrix} R \\ G \\ B \end{pmatrix} + \begin{pmatrix} o_1 \\ o_1 \\ o_1 \end{pmatrix}$	Light intensity change and shift $\begin{pmatrix} a & 0 & 0 \\ 0 & a & 0 \\ 0 & 0 & a \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix} + \begin{pmatrix} o_1 \\ o_1 \\ o_1 \end{pmatrix}$
RGB Histogram	-	-	-
$O_1, O_2$	-	+	-
Transformed color	+	+	+

**Figura 1** - Invariância dos descritores contra tipos de mudanças no modelo de deslocamento diagonal e suas especializações. A invariância é indicada com "+", a falta de invariância é indicada por "-".

## 2.3 Análise crítica dos resultados

### 2.3.1 Equalização de Histograma

No primeiro experimento foram realizados testes em quatro imagens escolhidas aleatoriamente do dataset com o objetivo de analisar o resultado do efeito de equalização de histograma na imagem, O resultado encontra-se na Figura 2:



**Figura 2** – Resultado da aplicação do efeito de equalização de histograma, nas duas primeiras colunas consta a imagem original e o seu respectivo histograma RGB enquanto as duas colunas à esquerda apresentam a imagem resultante e o histograma RGB após a aplicação.

Através da distribuição de frequência dos pixels da imagem podemos inferir se é uma imagem escura ou com pouca iluminação caso a distribuição esteja concentrada na esquerda, pixels com valores mais próximos do zero, ou clara / muito iluminada caso a distribuição esteja concentrada na direita.

Caso a distribuição de frequência esteja muito próxima de alguma região, ou seja, baixa amplitude no eixo X do histograma acontece o efeito de baixo contraste, o fato da grande maioria dos pixels estarem com valores muito próximos entre si

torna mais difícil a distinção de suas “características”. Ao aplicar o efeito de equalização de histograma é realizada uma função de transformação que usualmente é utilizada a própria CDF (cumulative distribution function) do histograma para aumentar o espalhamento / distribuição dos pixels na imagem e aproximar a intensidade dos pixels para a mesma frequência.

Os histogramas da Figura 1 apresentam o eixo y em escalas diferentes para a imagem original e a equalizada com o intuito de facilitar a percepção da distribuição, na primeira imagem o canal azul (B) possui a maior frequência relativa (0,045) próximo ao pixel de intensidade 100 e com amplitude de 90 pixels (entre 80 e 170) em sua imagem original e após a equalização do histograma os valores foram distribuídos entre os pixels 0 e 230, aumentando a amplitude da intensidade dos pixels em 255%. Na imagem resultante o efeito final é o aumento do contraste, destaque maior entre a diversidade/intensidade das cores na imagem e atenuação do efeito da exposição alta a iluminação ou falta de tal.

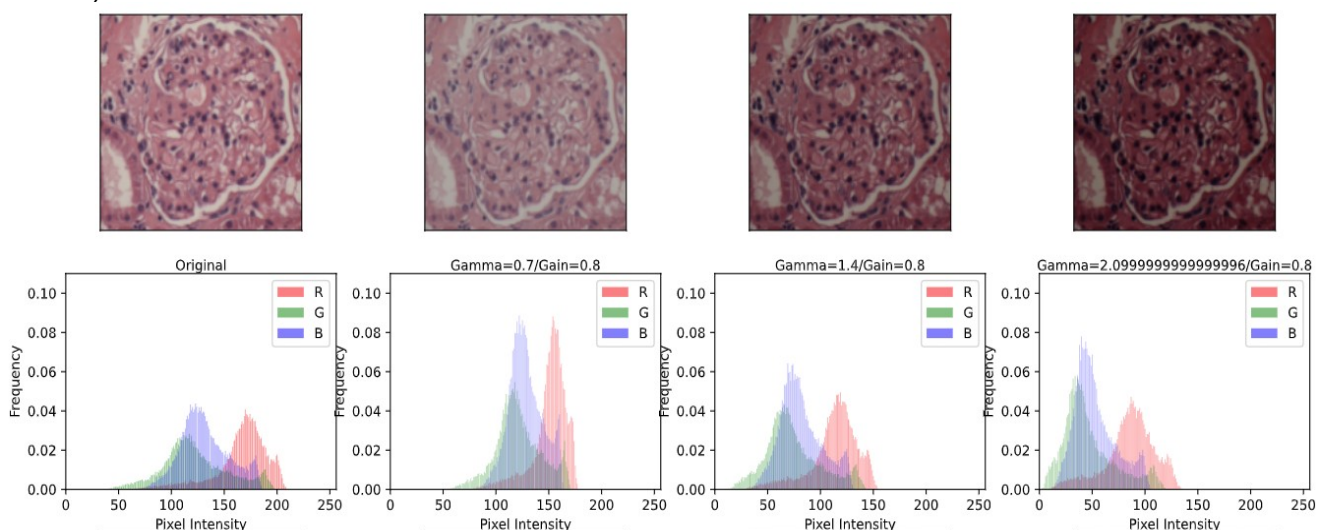
### 2.3.2 Correção de Gamma

A Correção Gamma que tem seu nome pela letra grega  $\gamma$ , foi idealizada para balancear a intensidade da luz devido a perturbação gerada ao transmitir informação em sinal analógico (sinais de tensão) para a tela das televisões as quais utilizavam tubo de raios catódicos (CRT), sendo determinada a intensidade do brilho de acordo a intensidade do raio de elétrons, porém esta relação não é linear e segue a lei da potência. Para o caso dos dispositivos embutidos com o CRT é representada por:


$$\text{GammaRGB} = \text{LinearRGB}^{1/\gamma}$$

Com a tecnologia atual os dispositivos não possuem mais o CRT, grande parte dos monitores são construídos por tecnologias de LED, LCD dentre outras, mas os softwares são desenvolvidos para projetar um pixel utilizando o espaço de cor RGB em dispositivos não lineares, no caso os dispositivos que não possuem CRT devem reproduzir o mesmo comportamento esperado através de software.

a)








**Figura 3** – Representação da mesma imagem com diferentes valores de gamma e constante de multiplicação (ganho), em a) gamma varia de 0.7 a 2.1 com ganho 0.8, b) gamma varia de 0.7 a 2.1 com ganho 1 e c) gamma varia de 0.7 a 2.1 com ganho 1.1.

Com valores de  $\gamma$  menores que um a função aumenta a intensidade dos pixels, deslocando o histograma para a direita e consequentemente resultando numa imagem mais clara, com valores maiores que um a imagem torna-se mais escuro, resultado do deslocamento para a esquerda do histograma. O valor usual de gamma para os dispositivos CRT é de 2.2 (McKesson, 2012). O aumento no ganho da imagem é responsável pelo crescimento da amplitude da intensidade, com o ganho variando entre 0.8 e 1.1 a imagem obteve uma amplitude de intensidade 50% maior (faixa de 50 a 100 para 50 a 150 no canal azul) com o

valor de gamma fixo em 2.1. Ao fixar o valor do ganho em 1 e variando o gamma entre 0.7 e 2.1 obtivemos um deslocamento da faixa de 80 a 210 para 40 a 170 de intensidade como é evidenciado na Figura 3. A correção de gamma é majoritariamente utilizada quando é necessário controlar a iluminação da imagem, deixando-a mais clara ou escura seguindo uma curva de crescimento mais natural (podendo trazer resultados melhores que o apenas o deslocamento de intensidade direto).

### 2.3.3 Filtro Gaussiano

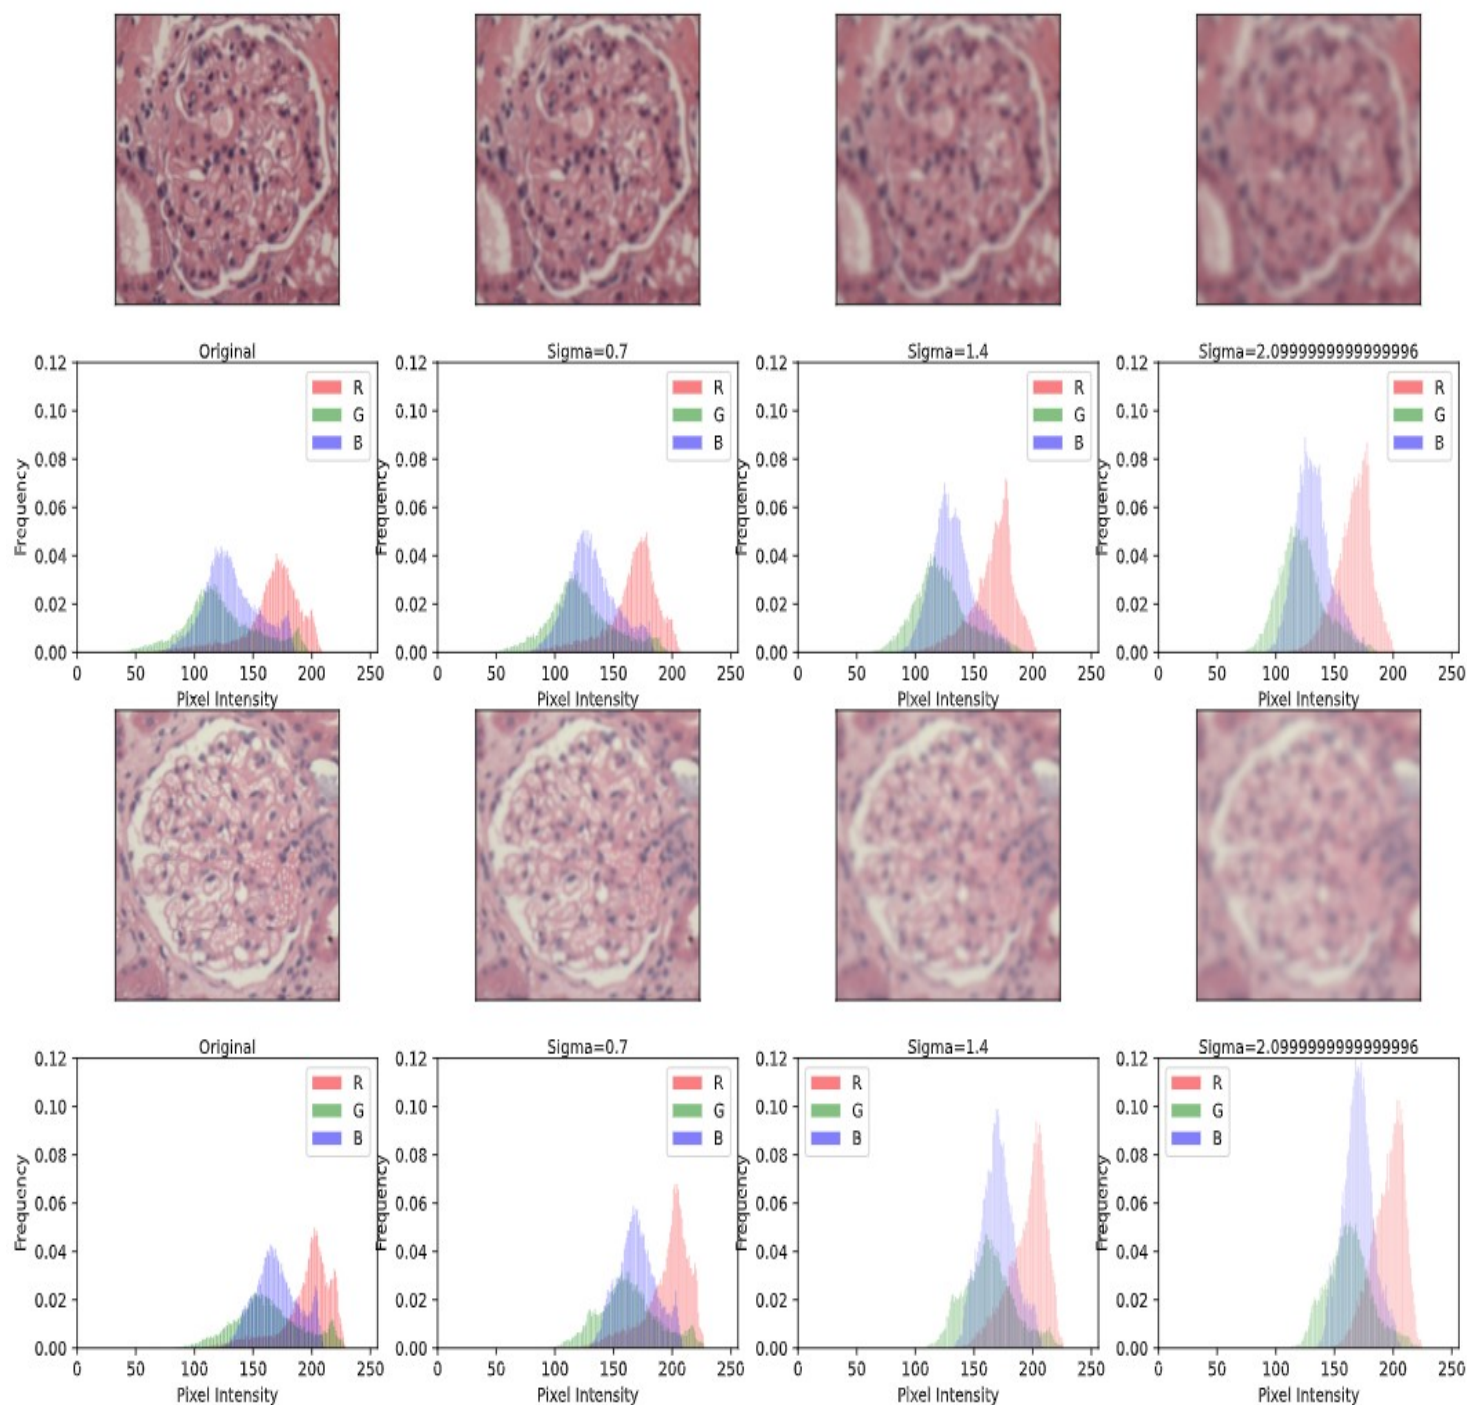
O filtro Gaussiano utiliza uma função Gaussiana (ou alguma aproximação) para alterar os valores de intensidade. Possui como característica principal a suavização do sinal. Para entender o funcionamento do filtro numa imagem, deve-se entender o conceito da curva gaussiana.



**Figura 4** – Curva Gaussiana com valores de desvio padrão evidenciados.

Como apresentado na Figura 4, com sigma apenas igual a 2 é possível representar 95.44% da área coberta pela curva, baseado nisso o desvio padrão é o elemento principal do filtro gaussiano, sendo o tamanho do kernel ajustado de acordo o valor de sigma. Com o mesmo comportamento da função gaussiana, o filtro considera cada vez menos os valores de intensidade dos pixels de acordo eles se afastam do centro do kernel, o resultado do filtro é demonstrado na Figura 5.





**Figura 5** – Resultado da aplicação do filtro gaussiano com sigma variando entre 0.7 e 2.1.

Quanto mais o parâmetro sigma cresce, menor se torna a variância da intensidade de pixels resultante, diminuindo o contraste, nível de detalhamento da

imagem e consequentemente dando uma impressão de borrão. É comumente utilizado para retirar ruídos indesejáveis e suavizar a imagem.


### 2.3.4 Filtro de Laplace

O filtro de Laplace é utilizado principalmente para detectar bordas tanto na direção vertical quanto horizontal, utiliza o operador de Laplace na imagem cuja equação é descrita pela Equação 1.


**Equação 1** – Filtro de Laplace.

$$Laplace(f) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

As bordas numa imagem nada mais são que regiões críticas na imagem onde há uma variação grande da intensidade dos pixels, para encontrar tais variações é possível realizar a primeira derivada a qual nos dá informações sobre os máximos e mínimos locais de uma função, como a imagem é uma figura 2-D então é possível realizar na vertical e horizontal (Sobel, 2014), porém o filtro de Laplace utiliza a segunda derivada encontrando assim o zero da função, onde aparecerão apenas nas bordas. Contudo o filtro de Laplace pela sua natureza matemática, é muito sensível a ruídos, podendo assim detectar perturbações indesejadas na imagem, a solução mais utilizada para contornar esse tradeoff é aplicar algum filtro de suavização como o filtro Gaussiano antes de aplicar o filtro de Laplace. O resultado do filtro de Laplace é apresentado na Figura 7 e a imagem invertida resultante é apresentada na Figura 6 apenas para facilitar a ilustração das bordas.



**Figura 6** – Imagem invertida resultante do filtro de Laplace para evidenciar as bordas encontradas.



**Figura 7** - Resultado do filtro de Laplace aplicado a imagem e seu respectivo histograma.

Por motivos não encontrados a mudança no tamanho do kernel não resultou em nenhuma diferença nos resultados obtidos ao aplicar o filtro de Laplace.

### 2.3.5 Invariância de cor

Mudanças na iluminação podem ser modeladas através do modelo de reflectância ou através de um mapeamento diagonal / Modelo de Von Kries (J. van de Weijer

et al., 2006) o qual considera uma imagem capturada por uma fonte de luz desconhecida, uma matriz de iluminação canônica e uma superfície em comum entre a imagem capturada pela iluminação desconhecida e a iluminação canônica além da adição de uma matriz coluna de offset para representar a componente de luz difusa do sistema como proposta por G.D. Finlayson et al. (1994) para representar o sistema de iluminação.

Baseado no modelo de Mapeamento Diagonal com Offset, J. van de Weijer et al. categorizou cinco mudanças nos valores de intensidade da imagem dos quais três deles foram implementados nesta seção, e os relacionou quanto a invariância resultante de alguns descritores de imagem.


Foram analisados as seguintes mudanças no Modelo de Diagonal com Offset:

- Mudança na intensidade da luz, que acontece quando os valores da diagonal são constantes;
- Deslocamento da intensidade da luz, resultante quando não há alteração na intensidade e há adição de luz difusa;
- Mudança e deslocamento da intensidade da luz, resultante da alteração na intensidade da luz e adição da luz difusa.

Durante esta seção foram avaliados três descritores quanto a variância na intensidade e deslocamento de luz:

- Histograma RGB
- O1, O2
- Transformada de Cor

Em todos os testes realizados nesta seção foram considerados  $A=B=C=2$  na diagonal de multiplicação para a transformação e intensidade,  $O_1=50$  para a adição da componente de iluminação difusa e a imagem da figura 8 para a extração das features.




**Figura 8** – Imagem utilizada para a extração das features da seção 2.3.5.

### 2.3.5.1 Histograma RGB

O histograma RGB é a representação da distribuição de frequência dos 3 canais de cor do espaço de cor RGB, não possuindo nenhuma invariância em relação a

alterações na iluminação estudadas. O resultado da extração do histograma RGB é apresentado na Figura 9.



**Figura 9** – Histograma RGB antes e após a aplicação das transformações de iluminação.

Nota-se a invariância nas três transformações através da diferença dos histogramas RGB em relação ao histograma RGB extraído da imagem original. Apenas a adição de intensidade da luz atenuou levemente a imagens para tons claros (deslocamento para a direita) enquanto a adição de luz difusa obteve mudanças drásticas quanto à iluminação da imagem devido a contante alta ( $O_1 = 50$ ) utilizada.

### 2.3.5.2 Histograma de oponentes

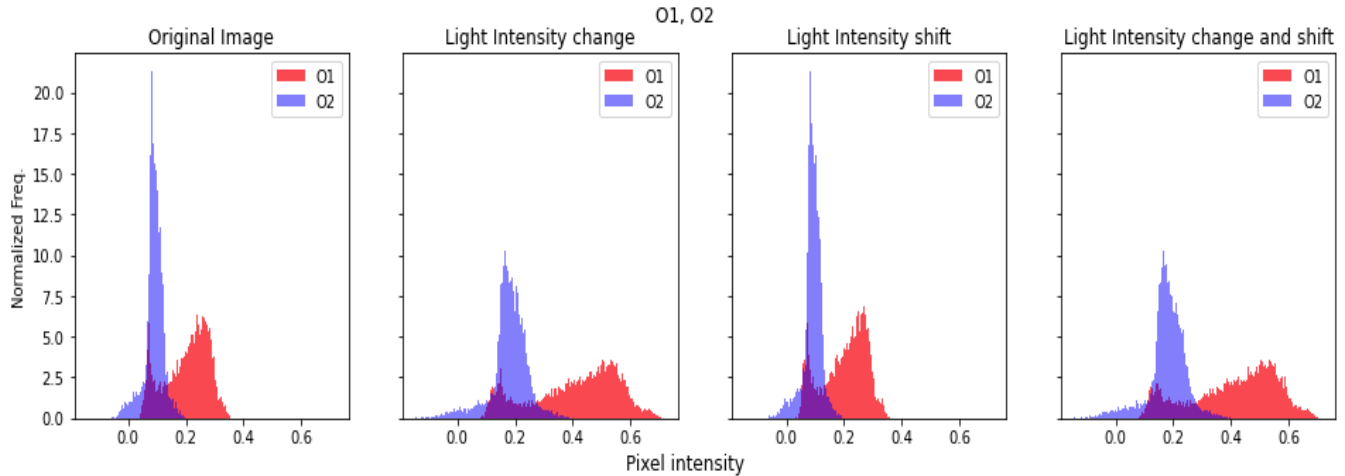
O histograma de oponentes é a combinação dos três canais  $O_1$ ,  $O_2$  e  $O_3$  do espaço de cor oponente. O histograma de oponentes obtém a vantagem do espaço de cor oponente o qual consta com dois canais cromáticos  $O_1$  e  $O_2$  que não recebem influencia da iluminação e apresentam apenas informações de cor, enquanto  $O_3$  é o único variante a iluminação. Podemos obter os três canais do espaço de cor oponente a partir de uma imagem no espaço de cor RGB através da Equação 2.

**Equação 2** – extração dos canais do espaço de cor oponente através de uma imagem em espaço de cor RGB.

$$\begin{pmatrix} O_1 \\ O_2 \\ O_3 \end{pmatrix} = \begin{pmatrix} \frac{R-G}{\sqrt{2}} \\ \frac{R+G-2B}{\sqrt{6}} \\ \frac{R+G+B}{\sqrt{3}} \end{pmatrix}$$



No caso foram extraídos apenas os canais  $O_1$  e  $O_2$ , apresentados na Figura 10.



**Figura 10** – histograma resultante da extração das features  $O_1$  e  $O_2$  do espaço de cor oponente.

Apenas a adição de luz difusa é invariante a transformação de iluminação. Se considerarmos a matriz coluna de adição com valores constantes, em consequência a natureza do espaço de cor, a adição da luz difusa vai ser anulada devido a subtração dos canais  $O_1$  e  $O_2$ , ao mudar a intensidade de iluminação a distribuição da intensidade dos pixels se torna mais esparsa, aumentando a amplitude de ambos os canais  $O_1$  e  $O_2$ .

### 2.3.5.3 Distribuição de cor transformada

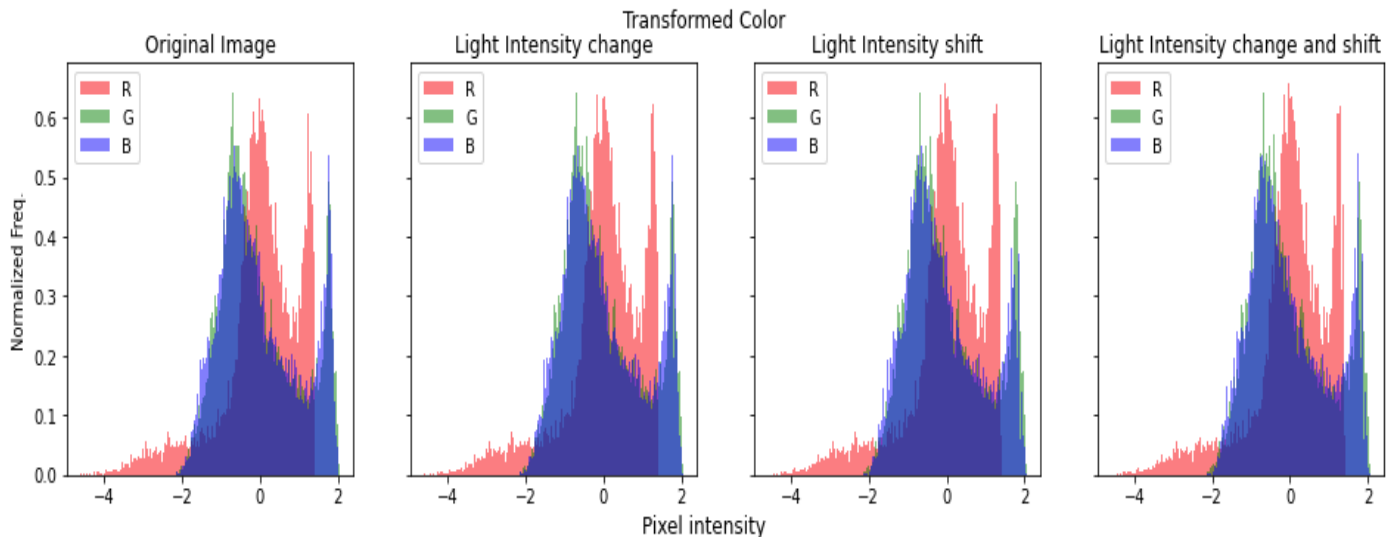
Apesar do histograma RGB não ser invariante a nenhuma condição de transformação da iluminação é possível obter a invariância em ambas as transformações de iluminação ao normalizar os canais de pixels RGB. Ao normalizar cada canal independentemente o descritor também é normalizado e não sofre variância na alteração da iluminação. Para normalizar basta aplicar a Equação 3 para os canais R, G e B.

**Equação 3** – Normalização dos canais RGB.

$$\begin{pmatrix} R' \\ G' \\ B' \end{pmatrix} = \begin{pmatrix} \frac{R - \mu_R}{\sigma_R} \\ \frac{G - \mu_G}{\sigma_G} \\ \frac{B - \mu_B}{\sigma_B} \end{pmatrix}$$



O histograma RGB resultante após a normalização dos canais é apresentado na Figura 11.



**Figura 11** – Histogramas RGB resultante após a normalização dos canais.

Após a normalização dos canais R, G e B o histograma torna-se invariante a alterações de iluminação, apresentando a mesma distribuição antes e após a aplicação do efeito.

Descritores de imagem são amplamente utilizados em sistemas de classificação através dos algoritmos de aprendizado de máquina (R. Datta, 2008), faz-se necessário ter um amplo conhecimento e acervo de descritores de imagem principalmente ao lidar com os efeitos adversos do mundo real como as diferentes alterações em iluminação. Apesar do custo computacional um pouco maior que os outros descritores estudados, o histograma RGB com os canais normalizados mostrou-se o mais eficiente para tarefas onde há mudança de iluminação, entretanto o histograma de oponentes torna-se mais viável em sistemas onde poderão existir apenas a existência de luz difusa.

Todos os códigos desenvolvidos encontram-se no repositório público: <https://github.com/Bruno-Mascarenhas/topicos-visao-computacional-1>

### 3 Referências

Charles A. Poynton (2003). Digital Video and HDTV: Algorithms and Interfaces. Morgan Kaufmann. pp. 260, 630. ISBN 1-55860-792-7

- G.D. Finlayson, M.S. Drew, and B.V. Funt, "Spectral Sharpening: Sensor Transformations for Improved Color Constancy," J. Optical Soc. Am. A, vol. 11, no. 5, p. 1553, 1994.
- J. van de Weijer, T. Gevers, and A. Bagdanov, "Boosting color saliency in image feature detection," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 28, no. 1, pp. 150–156, 2006.
- Koen E. A. v. de Sande et al, Evaluating Color Descriptors for Object and Scene Recognition, PAMI, 2010
- Learning Modern 3D Graphics Programming, Jason L. McKesson, Copyright © 2012 Jason L. McKesson, <https://paroj.github.io/gltut/index.html>
- MCHUGH, S. E. A. N. (n.d.). *Histogramas de Imagens – Tons e Contraste*. Histograms. Retrieved September 4, 2021, from <https://www.cambridgeincolour.com/pt-br/tutoriais/histograms1.htm>
- OpenCV: Laplace Operator*. (n.d.). OpenCV Tutorial. Retrieved September 4, 2021, from [https://docs.opencv.org/3.4/d5/db5/tutorial\\_laplace\\_operator.html](https://docs.opencv.org/3.4/d5/db5/tutorial_laplace_operator.html)
- OpenCV: Sobel Derivatives*. (n.d.). OpenCV Tutorial. Retrieved September 4, 2021, from [https://docs.opencv.org/3.4/d2/d2c/tutorial\\_sobel\\_derivatives.html](https://docs.opencv.org/3.4/d2/d2c/tutorial_sobel_derivatives.html)
- Spatial Filters - Laplacian/Laplacian of Gaussian*. (n.d.). Hypermedia Image Processing Reference (HIPR). Retrieved September 4, 2021, from <https://homepages.inf.ed.ac.uk/rbf/HIPR2/log.htm>
- Ting, P. (2014, June 1). *Fundamentos sobre Modelos de Iluminação* [Slides]. Dca.Fee.Unicamp. [https://www.dca.fee.unicamp.br/courses/IA727/2s2014/slides/iluminacao\\_avancada.pdf](https://www.dca.fee.unicamp.br/courses/IA727/2s2014/slides/iluminacao_avancada.pdf)
- University of Auckland. (2010, May 25). *Gaussian Filtering* [Slides]. Cs.Auckland. [https://www.cs.auckland.ac.nz/courses/compsci373s1c/PatricesLectures/Gaussian%20Filtering\\_1up.pdf](https://www.cs.auckland.ac.nz/courses/compsci373s1c/PatricesLectures/Gaussian%20Filtering_1up.pdf)

Wikipedia contributors. (2020, November 9). *Clipping (photography)*. Wikipedia.

[https://en.wikipedia.org/wiki/Clipping\\_\(photography\)](https://en.wikipedia.org/wiki/Clipping_(photography))

Wikipedia contributors. (2021, July 29). *Gamma correction*. Wikipedia.

[https://en.wikipedia.org/wiki/Gamma\\_correction](https://en.wikipedia.org/wiki/Gamma_correction)

Wikipedia contributors. (2021, August 30). *Histogram equalization*. Wikipedia.

[https://en.wikipedia.org/wiki/Histogram\\_equalization](https://en.wikipedia.org/wiki/Histogram_equalization)

R. Datta, D. Joshi, J. Li, and J.Z. Wang, "Image Retrieval: Ideas, Influences, and Trends of the New Age," ACM Computing Surveys, vol. 40, no. 2, pp. 1-60, 2008.

Sobel, Irwin. (2014). An Isotropic 3x3 Image Gradient Operator. Presentation at Stanford A.I. Project 1968.