

Bruno Severino Mascarenhas

Relatório das Práticas Laboratoriais

Visão Computacional e Reconhecimento  
de Padrões

Salvador

2021

## Sumário

1 Prática 2 – Extração de características.....	3
1.1 Objetivo.....	3
1.2 Descrição da prática.....	3
1.2.1 Roteiro I.....	3
1.2.2 Roteiro II.....	3
1.2.3 Roteiro III.....	3
1.3 Análise crítica dos resultados.....	4
1.3.1 Local Binary Pattern (LBP).....	4
1.3.2 Grey-Level Co-occurrence Matrix (GLCM).....	6
1.3.3 Filtro de Sobel.....	9
1.4 Referências.....	11

# 1 Prática 2 – Extração de características

## 1.1 Objetivo

Nessa prática são apresentadas algumas técnicas de extração de features, com base nos descritores LBP, GLCM e Sobel. O objetivo é compreender o processo de extração e geração de um vetor de features, que será objeto de práticas posteriores.

## 1.2 Descrição da prática

### 1.2.1 Roteiro I

1. Aplique o operador LBP nos data sets gerados no Capítulo 2 para extrair as features de cada imagem. Em seguida, salve os vetores de features resultantes em uma única matriz, de modo que o número de linhas da matriz corresponda ao número de imagens do data set, e as colunas sejam do tamanho do vetor de features da imagem.
2. Verifique a representação desta feature em formato de imagem. Para tanto, utilize 3 imagens do data set gerado na etapa de pré-processamento.

### 1.2.2 Roteiro II

1. Calcule a propriedade de Contraste proposto por Haralick por meio de GLCM nos data sets gerados no Capítulo
2. Em seguida, salve os vetores de features resultante em uma única matriz, de modo que o número de linhas da matriz corresponda ao número de imagens do data set, e as colunas sejam do tamanho do vetor de features da imagem;
2. Verifique a representação desta feature em formato de imagem. Para tanto, utilize 3 imagens do data set gerado na etapa de pré-processamento.

### 1.2.3 Roteiro III

1. Aplique o operador Sobel nos data sets gerados anteriormente no Capítulo 2. Em seguida, salve os vetores de features resultante em uma única matriz, de modo que o número de linhas da matriz corresponda ao número de imagens do data set, e as colunas sejam do tamanho do vetor de features da imagem;

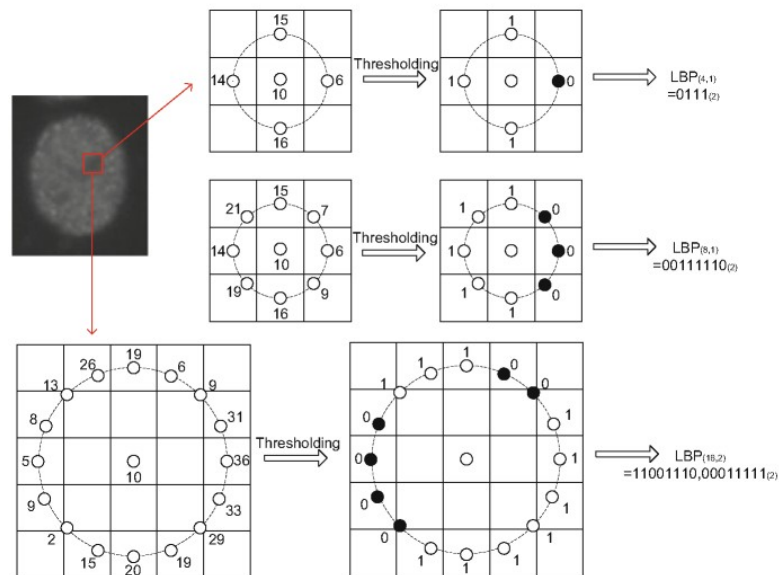
2. Verifique a representação desta feature em formato de imagem. Para tanto, utilize 3 imagens do data set gerado na etapa de pré-processamento.

## 1.3 Análise crítica dos resultados


### 1.3.1 Local Binary Pattern (LBP)

O extrator de feature Local Binary Pattern (LBP), foi desenvolvido para retirar características locais de textura (Xu, 2017). O algoritmo analisa os tons de cinza da imagem através de patches e determina o valor do pixel central por meio de comparações com os pixels da vizinhança escolhida.

A quantidade de pontos que serão comparados e o raio da vizinhança são parâmetros de entrada para o algoritmo. Quanto maior o raio, mais pontos da vizinhança deverão ser considerados, o valor do pixel central é considerado como threshold durante a comparação e, a depender da heurística escolhida, será formado um valor em binário resultante das comparações. O número binário resultante do processo é transformado em valor decimal novamente para ocupar o valor do pixel central na matriz resultante do LBP. Na Figura 1 é ilustrado o processo resultante da escolha de diferentes quantidades de pontos e valores de raios.

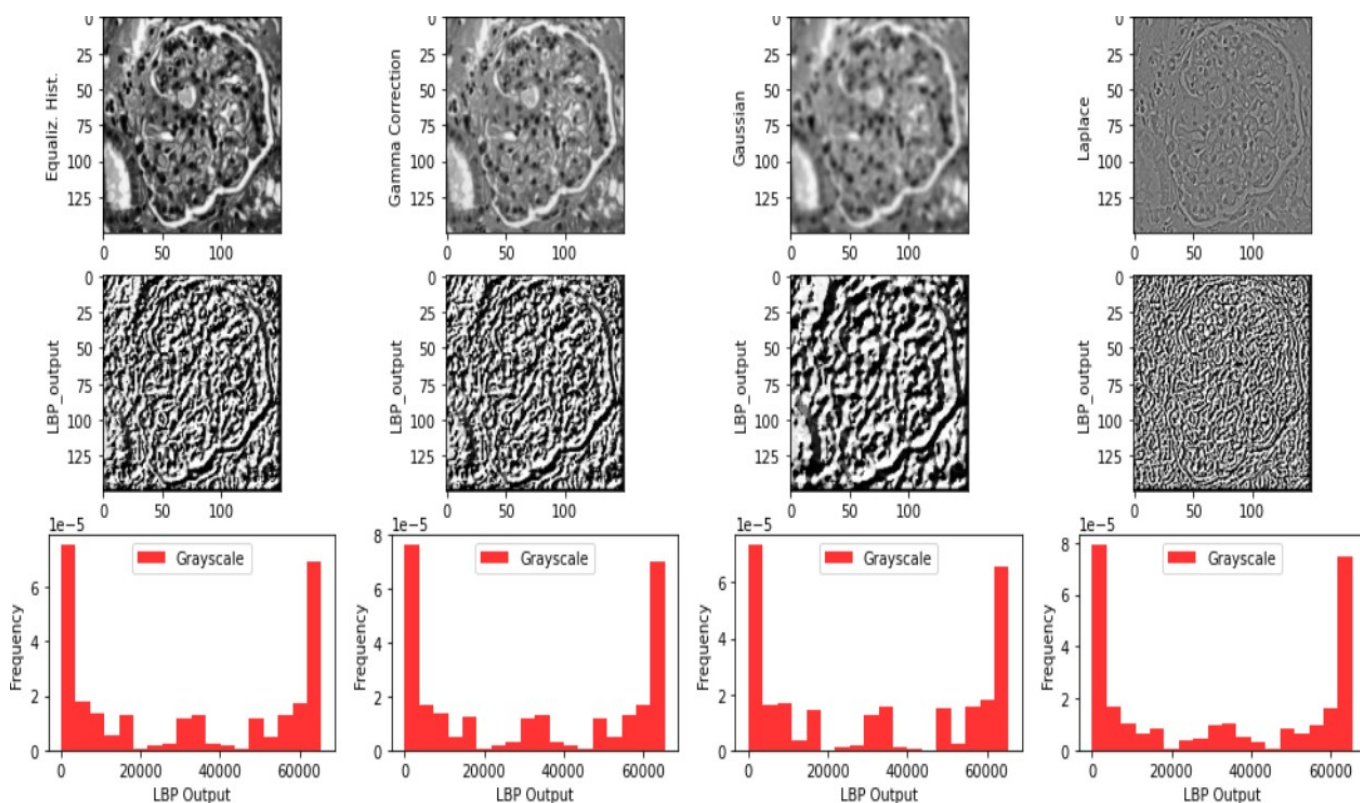


**Figura 1** - Processo resultante da escolha de diferentes valores de pontos e raio da vizinhança. Figura extraída do livro *Cellular Image Classification* (Xu, 2017).



**Figura 2** – Representação em escala de cinza de três imagens escolhidas aleatoriamente e seus respectivos histogramas. Na primeira e segunda linha correspondem à imagem original enquanto a terceira e quarta linha correspondem ao resultado da aplicação do algoritmo LBP.


O resultado da aplicação do algoritmo LBP no dataset dos glomérulos e seu respectivo histograma é apresentado na Figura 2. Foram escolhidos os valores dos parâmetros raio e quantidade de pontos como 2 e 18 respectivamente, após alguns testes visuais e análises no histograma resultante, estes valores de parâmetros foram o que visualmente separavam o histograma em classes mais distintas, i.e. picos e áreas de alta densidade de pixels mais bem definidas. É apresentado na Figura 3 o resultado da aplicação do algoritmo nos diferentes conjuntos de dados gerados através da prática anterior.



**Figura 3** – Resultado da aplicação do algoritmo LBP nas imagens dos datasets gerados na prática anterior.

### 1.3.2 Grey-Level Co-occurrence Matrix (GLCM)

Grey-Level Co-occurrence Matrix, GLCM, é uma matriz de frequência das combinações de intensidade de pixels diferentes existentes numa imagem ou vizinhança. É um método para análise espacial de texturas. Utiliza-se estatística de segunda ordem para realizar as comparações, o que significa que ele considera a relação entre dois pixels, no caso um pixel pivô é considerado como referência o qual é comparado par a par com os outros pixels da vizinhança. É possível determinar a distância e a direção em que as comparações serão realizadas. Considerando a distância como dois pixels e direção esquerda por exemplo, a matriz GLCM será a frequência das combinações das diferentes intensidades de pixels da vizinhança, comparando o pivô apenas com até dois pixels à sua esquerda. Na Figura 4 é apresentada uma matriz GLCM resultante de uma matriz hipotética de pixels, considerando a direção esquerda e distância igual a 1.




**Figura 4** – Matriz GLSM à direita e matriz hipotética de pixels a esquerda, considerando a direção esquerda e distância igual a 1 para o algoritmo. Extraído de Verma et al. (2015).

Haralick et al. (1973) propôs a extração de 14 características diferentes da matriz GLCM, como: energia, entropia, contraste, correlação, diferença de momento, inércia, dentre outras. A característica de Contraste a qual foi extraída nesta prática está representada na Equação 1.

**Equação 1** – Característica Contraste de Haralick

$$C = \sum_{i,j} p_{i,j} (i - j)^2$$



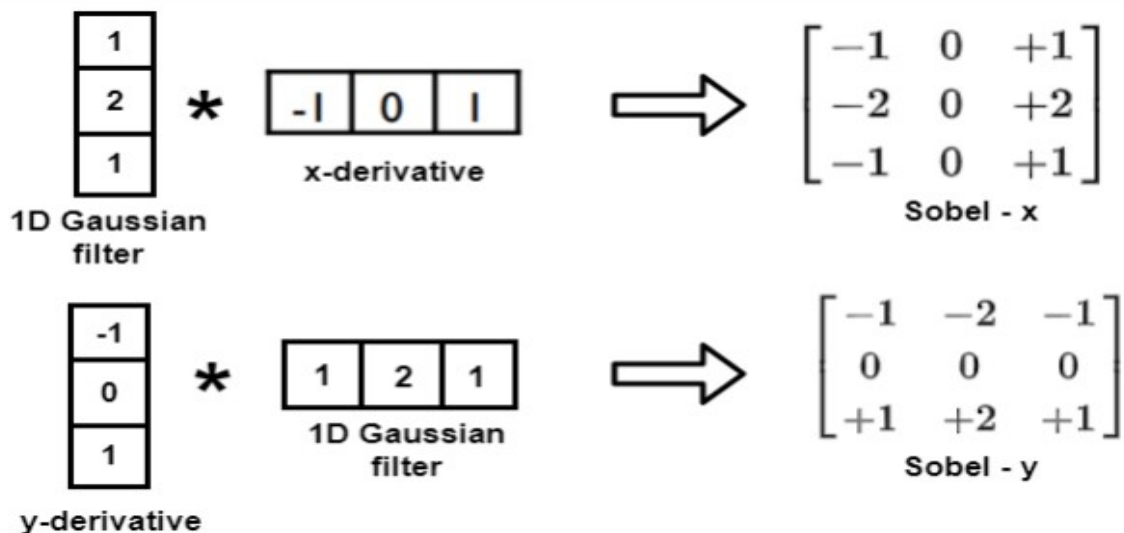
**Figura 5** – Representação em formato de imagem da característica de Contraste. Na primeira coluna são apresentadas as imagens originais do conjunto de dados, na segunda e terceira coluna são representados respectivamente, o resultado da característica de contraste em formato de imagem e o seu histograma.

A característica de contraste evidencia a diferença de tons claros e escuros dentro da vizinhança, os valores na diagonal principal da matriz GLCM possuem peso nulo, entretanto o peso aumenta exponencialmente conforme os valores se afastam da diagonal, Hall-Beyer (2017).




### 1.3.3 Filtro de Sobel

O filtro de Sobel é utilizado principalmente para detectar bordas tanto na direção vertical quanto horizontal, utiliza o operador de Sobel.



**Figura 6** - Kernels resultantes da aplicação de filtros Gaussianos em conjunto com operadores de Sobel para os eixos x e y. Extraído de Atul (2019).

As bordas numa imagem nada mais são que regiões críticas na imagem onde há uma variação grande da intensidade dos pixels, para encontrar tais variações é possível realizar a primeira derivada a qual nos dá informações sobre os máximos e mínimos locais de uma função, como a imagem é uma figura 2-D então é possível realizar na vertical e horizontal (Sobel, 2014), porém o operador de Sobel é muito sensível a ruídos, podendo assim detectar perturbações indesejadas na imagem, a solução mais utilizada para contornar este problema é a aplicação de algum filtro de suavização, como o filtro Gaussiano, antes de aplicar o operador de Sobel. O resultado do filtro de Sobel aplicado ao conjunto de dados é apresentado na Figura 7.



**Figura 7** - Resultado da aplicação do operador de Sobel para os eixos X e Y nas imagens do dataset.

Todos os códigos desenvolvidos encontram-se no repositório público:  
<https://github.com/Bruno-Mascarenhas/topicos-visao-computacional-1>

## 1.4 Referências

Xu, X., Wu, X., & Lin, F. (2017). Cellular image classification. Cham: Springer International Publishing.

Haralick, R. M., Shanmugam, K., & Dinstein, I. H. (1973). Textural features for image classification. IEEE Transactions on systems, man, and cybernetics, (6), 610-621.

Verma, Manisha & Raman, Balasubramanian & Murala, Subrahmanyam. (2015). Local Extrema Co-occurrence Pattern for Color and Texture Image Retrieval. Neurocomputing. 165. 255–269. 10.1016/j.neucom.2015.03.015.

Hall-Beyer, M. (2017, March). GLCM Texture: A Tutorial v. 3.0. PRISM: University of Calgary's Digital Repository.  
[https://prism.ucalgary.ca/bitstream/handle/1880/51900/texture%20tutorial%20v%203\\_0%20180206.pdf?sequence=11&isAllowed=y](https://prism.ucalgary.ca/bitstream/handle/1880/51900/texture%20tutorial%20v%203_0%20180206.pdf?sequence=11&isAllowed=y)

Atul, K. (2019, May 24). *First-order Derivative kernels for Edge Detection*. TheAILearner. <https://theailearner.com/tag/sobel-operator/>

Sobel, Irwin. (2014). An Isotropic 3x3 Image Gradient Operator. Presentation at Stanford A.I. Project 1968.